华为 SSD 读写冲突建模思路

Zhejiang University

2021 年 12 月 11 日

目录

1. 问题描述
2. 建模思路

读写冲突问题概述

主机以一定特征访问 SSD 设备，访问包括读/写（擦除？）两种类型。SSD 设备对两种访问的应答响应时间不同。SSD 设备的应答执行单元由若干并发单元组成。单位并发单元同时只能执行一个请求。若读和写访问指向同一笔数据的指针，则必须由同一并发单元执行。SSD 设备除处理主机的读写请求外，还要执行内部 GC 触发的读/写/擦三类任务。主机访问的响应优先级高于 SSD 内部任务。该应用背景衍生了下述三大问题：

1. 如何调度 SSD 的并发单元，以尽可能多、快地响应主机请求？
2. 如何识别主机的访问特征，哪些是关键特征？
3. 如何调度来自主机和 SSD 内部的请求，以尽可能减少 SSD 内部管理行为为主机应答响应能力的干扰？
4. 机理建模，通过并发数据、介质潜伏期参数（?）、调度策略，可以给出 die 的空闲率、稳态带宽（?）等关键参数。
5. 给出机理模型指导调度策略寻优方法。

SSD 内部存储结构

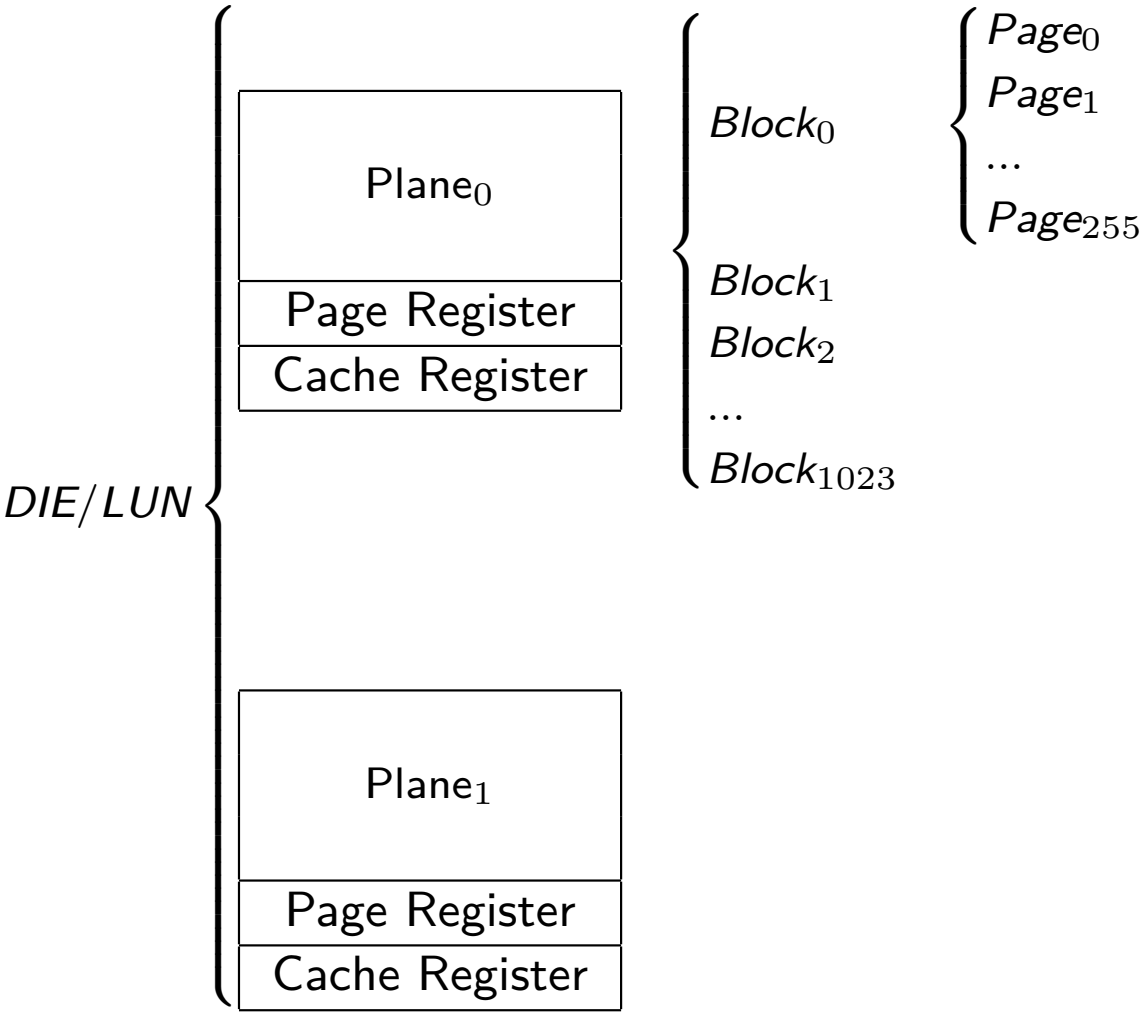
DIE/LUN
Plane$_0$
Page Register
Cache Register
Plane$_1$
Page Register
Cache Register
Block$_0$
Block$_1$
Block$_2$
...
Block$_{1023}$
Page$_0$
Page$_1$
...
Page$_{255}$

SSD 读/写原理

每个 Plane 有独立的 Cache Register 和 Page Register，其大小等于一个 Page 的大小。
SSD 的读/写方法均有两种，分为正常读/写和 Cache 读/写。以写为例，SSD 在写某个 Page 时，

- 正常写是先把数据从主控传输到该 Page 所对应 Plane 的 Cache Register 中，然后再把整个 Cache Register 中的数据写到闪存阵列。
- Cache 写是闪存在写前一个 Page 数据的同时（Page 闪存介质），传输下一个要写的数据到 Cache Register（主控 Cache Register），这样数据在闪存总线传输可以隐藏在前一个 Page 的写时间里。

SSD 读/写原理

- 闪存写入时间: 一个 Page 的数据从 Page Register 当中写入闪存介质的时间
- 闪存读取时间: 一个 Page 的数据从闪存介质读取到 Page Register 的时间。

不包含数据从闪存到主控之间的数据传输时间，也不包含数据在 Cache Register 和 Page Register 之间的传输时间

SSD 读写冲突问题

1. 当主控在某一时刻关于同一个 DIE/LUN 同时存在读和写（擦）的命令，由于 DIE/LUN 同时只能处理一种命令，发生冲突。分为三类：读写冲突，读读冲突，写写冲突
2. 内部 GC 与外部读写冲突（不考虑）

建模思路

建模遇到的问题

1. 主机对 SSD 发出的写命令，到达 SSD 的主控时，写入地址是由主控实时分配的，还是到达主控时就已经确定了的？
2. 若写入地址是由主控实时分配的，SSD 的读写操作指向同一 DIE 引发冲突时，能否把写的物理地址改变，从而让冲突的写操作到空闲的 DIE 完成？

建模思路

可调度的部位

- 主机，在读写命令发送给 SSD 控制器之前，可以对读写命令序列进行初步打包分配，此处即可将冲突的读取命令分配到不同批次从而避免读读冲突
- SSD 控制器，存有数据分配方案，会对写入进行分配，也会控制读取，此处需要尽量避免读写冲突
- SSD 内部存储，GC 和 wear leveling(WL) 会与外部读写造成冲突(不考虑)

建模思路

两阶段优化

- 主机，对于读写操作需要设计初步批次分配算法
- SSD 控制器，设计读写分配方案

建模思路

SSD 控制器

- 确定可调度范围，以时间 Δt 划分时段，时段内主控接收到的所有读写命令的集合作为可调度的范围。将原问题转化为时段内的静态规划问题。
- 五种时间
  - T_1: 写操作中单个 Page 从 SSD 主控传输到 Cache Register 的时间
  - T_2 写操作中单个 Page 从 Page Register 写入到内存介质中的时间
  - T_3 读操作中单个 Page 从存储介质读取到 Page Register 的时间
  - T_4 读操作中单个 Page 从 Cache Register 读取到主控的时间
  - T_5 读写发生冲突时，读或写需要等待的时间，取决于需等待的读或写的次数。

建模思路

将问题简化为平行机排序问题和背包问题的综合变种。
给定读写命令集 S，将每一个 DIE 看作一台机器（machine），每个读/写命令或者读/写命令的组合看作工件 (job)，一个或一批读写命令的操作时间看成每个工件的加工时间，则原问题等价于求最快完成所有工件加工的方案。
对于工件，我们考虑除单个读/写命令可以看作一个工件外，一批做 Multi-Plane 操作的读/写命令组合也可以看作一个工件。由于对于每个 DIE，它包含的每个 Plane 上都写有不同数量的数据，因此，可以记录每个 Plane 的闲置容量作为背包约束的容量，对于 Multi-Plane 操作的对应的工件来说，只有每个 Plane 上都有空余时才能进行。更多的细节需要对问题的背景进一步了解才能确定。

平行机排序问题

- m 个相同的机器 (machines)
- n 个工件 (jobs) 对应完成用时 $p_1, \ldots, p_n$
- variable $x_{ij} = \begin{cases} 1 & \text{如果工件}j\text{分配给机器}i \\ 0 & \text{其他} \end{cases}$

整数规划模型:

$$
\begin{array}{rrll}
 & \min & C_{\max} & \\
\text{s.t.} & \sum_{j=1}^{n} x_{ij} p_j & \leq C_{\max} & i = 1, \ldots, m \\
 & \sum_{i=1}^{m} x_{ij} & = 1 & j = 1, \ldots, n \\
 & x_{ij} & \in \{0, 1\} & i = 1, \ldots, m; j = 1, \ldots, n
\end{array}
$$

The End